



Санкт-Петербургский государственный университет
Кафедра компьютерных технологий и систем

Вероятностный апостериорный анализ трудоемкости MSD-сортировки

Ерхов Александр Александрович, группа 23.Б12-ПУ

Научный руководитель: Никифоров Константин Аркадьевич, доцент кафедры моделирования электромеханических и компьютерных систем, кандидат физико-математических наук.

Санкт-Петербург
2026

Цель – провести апостериорный анализ трудоёмкости MSD-сортировки на основе результатов полученных в “A Limit Theorem for Radix Sort and Tries with Markovian Input” [1].

Задачи:

- Исследование материала [1].
- Разработка алгоритма на основе модели, приведенной в [1].
- Проведение вычислительного эксперимента.
- Проверка вхождения математического ожидания и дисперсии в соответствующие доверительные интервалы.
- Проверка центральной предельной теоремы с помощью критерия Пирсона.

Постановка задачи

Будем рассматривать словарь (массив слов). Пусть алфавит $\Sigma = \{0, 1\}$. Количество символов в слове непостоянно. Количество слов в словаре также заранее не известно – n .

Генерация словаря. Каждое слово генерируется независимо друг от друга. Начальный символ, в каждом слове, выбирается согласно начальному распределению μ , т. е. $P(\xi = 0) = \mu_0$, $P(\xi = 1) = \mu_1$, где $\mu_0 + \mu_1 = 1$. Далее используем марковские цепи: каждый следующий символ зависит только от предыдущего, в соответствии с матрицей переходов $P = [p_{ij}]$, $i, j \in \{0, 1\}$. При этом $p_{ij} \neq \frac{1}{2}, \forall i, j$ (Этот случай исключается как тривиальный). Также здесь введем понятие *энтропии*:

$$H = \sum_i \pi_i H_i, \text{ где} \quad (1)$$

$$H_i = - \sum_j p_{ij} \log p_{ij}, \pi_0 = \frac{p_{10}}{p_{01} + p_{10}}, \pi_1 = \frac{p_{01}}{p_{01} + p_{10}}.$$

$$\mathbb{E}[B_n^\mu] = \frac{1}{H} n \log n + O(n); \quad (2)$$

$$\text{Var}(B_n^\mu) = \sigma^2 n \log n + O(n\sqrt{\log n}), \text{ где} \quad (3)$$

$$\sigma^2 = \frac{\pi_0 p_{00} p_{01}}{H^3} \left(\log(p_{00}/p_{01}) + \frac{H_1 - H_0}{p_{01} + p_{10}} \right)^2 + \\ + \frac{\pi_1 p_{10} p_{11}}{H^3} \left(\log(p_{10}/p_{11}) + \frac{H_1 - H_0}{p_{01} + p_{10}} \right)^2;$$

$$\frac{B_n^\mu - \mathbb{E}[B_n^\mu]}{\sqrt{\text{Var}(B_n^\mu)}} \xrightarrow{d} \mathcal{N}(0, 1). \quad (4)$$

Реализация

```
1 def MSD_sort(  
2     arr: list[str],  
3     n: int  
4 ) -> int:  
5     stack = [(0, 0, n)] # digit, left, right  
6     total_count = 0  
7  
8     while stack:  
9         digit, left, right = stack.pop()  
10        if right-left <= 1 or digit >= max(len(arr[i]) for i in  
11        range(left, right)):  
12            continue  
13        count, groups = counting_sort(arr, left, right, digit)  
14        total_count += count  
15        for i in range(1, len(groups)):  
16            new_left, new_right = groups[i]  
17            if new_right - new_left > 1:  
18                stack.append((digit+1, new_left, new_right))  
19  
20    return total_count
```

Вычислительный эксперимент

$n = 10, 20, 40, \dots, 4096$ – количество слов

$k = 2n$ – длина слова

$\Delta = n$ – на столько может изменяться длина слова ($k \pm \Delta$)

$\mu = 0.7$ – начальное распределение

$P = [0.7, 0.2]$ – матрица переходов

$K = 60$ – количество экспериментов для каждого n

Для каждой выборки:

$$\bar{X} = \frac{1}{K} \sum_{i=1}^K X_i$$

$$S^2 = \frac{1}{K-1} \sum_{i=1}^K (X_i - \bar{X})^2$$

$$\alpha = 0.05 \Rightarrow t_{crit} = 2.001$$

$$CI = [\bar{X} - t_{crit} \frac{S}{\sqrt{K}}, \bar{X} + t_{crit} \frac{S}{\sqrt{K}}]$$

Нахождение констант:

$$\nexists C : \frac{1}{H} n \log n + Cn \in CI, \forall n$$

$$\exists C : \frac{2}{H} n \log n + Cn \in CI, \forall n$$

$$\Delta = \bar{X} - \frac{1}{H} n \log n$$




Рис. 1: График нормированных остатков

Так как по результату (4) наша случайная величина имеет нормальное распределение, то для проверки дисперсии имеет место χ^2 -интервал:

$$CI = \left[\frac{(K-1)S^2}{\chi_{1-\alpha/2, K-1}^2}, \frac{(K-1)S^2}{\chi_{\alpha/2, K-1}^2} \right]$$

$$\exists C : \sigma^2 n \log n + Cn\sqrt{\log n}$$

$$K = \left(\frac{z_{1-\alpha/2}\sigma}{\delta} \right)^2$$




Рис. 2: Гистограмма частот

$$b = 1 + \lfloor \log_2 K \rfloor$$

Поставленные в разделе *Введение* цель и задачи выполнены. Вероятностная модель, описывающая поведение MSD-сортировки на данных, сгенерированных марковским источником, доказала свою точность. Алгоритм, несмотря на высокую трудоемкость в худшем случае, поддается строгому прогнозированию в среднем случае при известной матрице переходов алфавита.



Санкт-Петербургский государственный университет
Кафедра компьютерных технологий и систем

Вероятностный апостериорный анализ трудоемкости MSD-сортировки

Ерхов Александр Александрович, группа 23.Б12-ПУ

Научный руководитель: Никифоров Константин Аркадьевич, доцент кафедры моделирования электромеханических и компьютерных систем, кандидат физико-математических наук.

Санкт-Петербург
2026